



Universidad **Ricardo Palma**

RECTORADO
PROGRAMA DE ESPECIALIZACIÓN EN CIENCIA DE DATOS

Formamos seres humanos para una cultura de paz

TALLER DE ESTADÍSTICA PARA LA CIENCIA DE DATOS



R + Python



MÓDULO 5 : ANALISIS MULTIVARIADO II

Análisis de Regresión No Paramétrica



A nuestro recordado Maestro

Dr. Erwin Kraenau Espinal, Presidente de la Comisión de Creación de la Maestría en Ciencia de los Datos



TALLER DE ESPECIALIZACIÓN “STATISTICAL SCIENCE INTRODUCTION”

TALLER DE ESTADÍSTICA PARA CIENCIA DE DATOS

EXPOSITORES



José Antonio Cárdenas Garro
UNMSM

MSc in Data Science Candidate
Promotion "Erwin Kraenau Espinal"
Universidad Ricardo Palma



André Omar Chávez Panduro
UNMSM

MSc in Data Science Candidate
Promotion "Erwin Kraenau Espinal"
Universidad Ricardo Palma

**Predictive Modelling
Specialist**



Data Scientist



**Portfolio and
Consumption Analyst**



**Customer Intelligence
Analyst**



Data Analyst



Data Analyst



Correo : josecardenasgarro@gmail.com
LinkedIn : www.linkedin.com/in/jos%C3%A1-antonio-c%C3%A1rdenas-garro-599266b0

Correo : andrecp38@gmail.com /
09140205@unmsm.edu.pe
LinkedIn : www.linkedin.com/in/andr%C3%A9-ch%C3%A1vez-a90078b9



TALLER DE ESPECIALIZACIÓN "STATISTICAL SCIENCE INTRODUCTION"

« En medio de la dificultad,
reside el nacimiento de la
OPORTUNIDAD»



AGENDA

- Introducción
- Formas Paramétricas
- Formas No Paramétricas



TALLER DE ESPECIALIZACIÓN “STATISTICAL SCIENCE INTRODUCTION”

INTRODUCCION

La teoría de los **métodos no paramétricos** desarrolla procedimientos de inferencia estadística, que no realizan una suposición explícita con respecto a la forma funcional de la distribución de probabilidad de las observaciones de la muestra.

Si bien en la **estadística no paramétrica** también aparecen modelos y parámetros, ellos están definidos de una manera más general que en su contrapartida paramétrica.

MODELO

$$Y_i = r(X_i) + \varepsilon_i, \quad i = 1, \dots, n$$

FORMAS PARAMÉTRICAS


$$p = \frac{e^z}{1 + e^z} = \frac{1}{1 + e^{-z}},$$

siendo


$$Z = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k$$



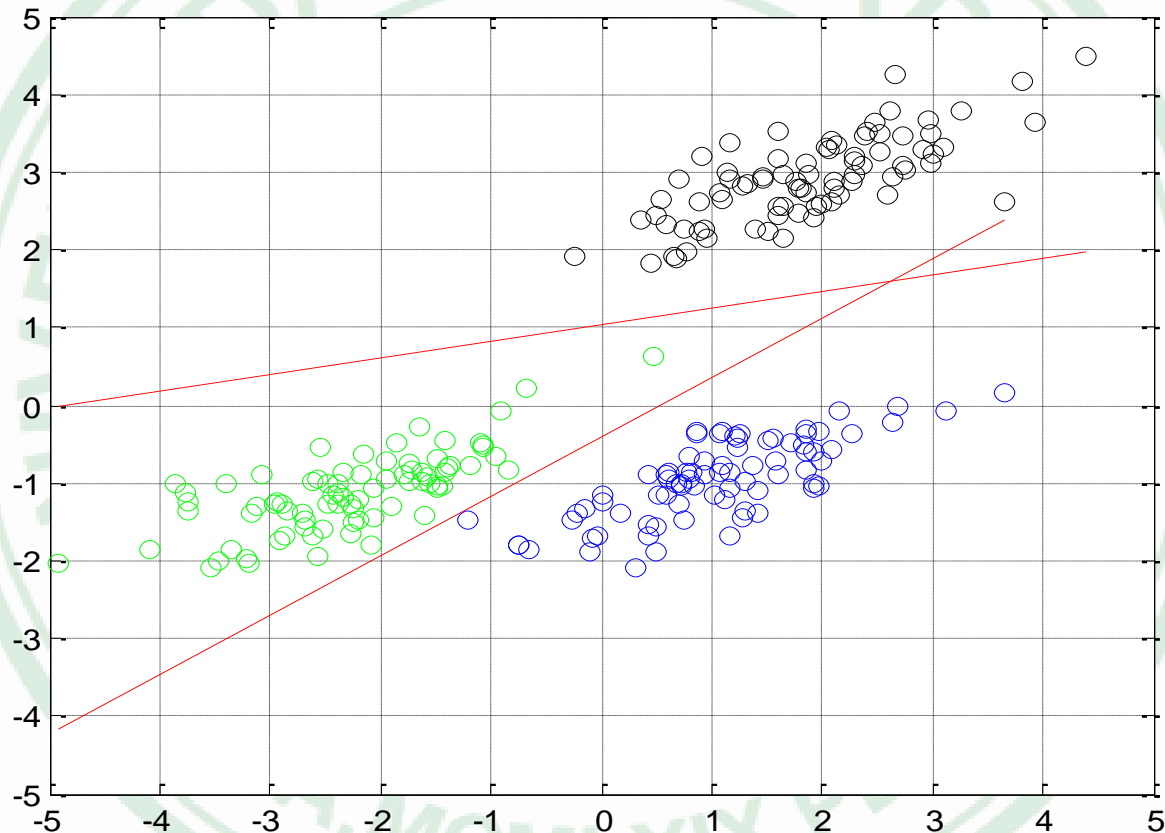
CLASIFICACIÓN MEDIANTE LOS VECINOS MÁS CERCANOS



CLASIFICACIÓN MEDIANTE LOS VECINOS MÁS CERCANOS



FUNCIONES DISCRIMINANTES




FORMAS NO PARAMÉTRICAS

REGRESORGRAMA

- En el **Regresograma** se divide el intervalo de los valores de la variable predictora en varios subintervalos (usualmente 5). La amplitud de los subintervalos se elige de tal manera que haya aproximadamente igual número de datos en cada uno de ellos.
- Luego se promedia los valores de la variable de respuesta en cada subintervalo. Esto determina varios segmentos de línea que al unirse forma el **regresograma**. Lo malo de este estimador es que no es suave porque hay saltos en cada punto de corte.

REGRESORGRAMA



RUNNING


Primero, para cada valor de x_i se define una vecindad simétrica $N(x_i)$ que contenga a dicho punto. La simetría esta en el sentido que el número de puntos k es el mismo tanto a la derecha como a la izquierda del punto dado, en los extremos esto no se puede lograr pero se trata de estar lo más cerca posible.

$$N(x_i) = \{\max(i - k, 1), \dots, i - 1, i, i + 1, \dots, \min(i + k, n)\}.$$


Luego se calcula el suavizador por running means, running medians ó running lines en el punto x_i .

Método	Suavizador $s(x_i)$
Running Means	$s(x_i) =$ promedio de las y 's en $N(x_i)$
Running Medians	$s(x_i) =$ mediana de las y 's en $N(x_i)$
Running Lines	$s(x_i) =$ valor estimado de la regresión mínimo cuadrática para $x = x_i$ que se obtiene usando los puntos (x_i, y_i) con x_i que cae en $N(x_i)$


RUNNING MEANS



RUNNING MEDIANS



RUNNING MEANS Y MEDIANAS





¡Gracias!

TALLER DE ESPECIALIZACIÓN “STATISTICAL SCIENCE INTRODUCTION”