

# Análisis de tweets contexto peruano

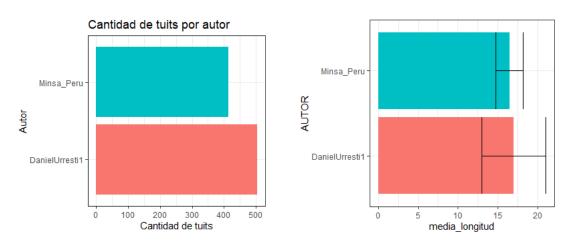
#### **Alumnos: Leonela Tacure Purizaca**

Se utilizo el conjunto de datos extraídos de twitter, se obtuvo 18 variables con 1,073 observaciones; al realizar el análisis se selecciono solo 4 variables importantes:

- ✓ ID: Educación media de los titulares ocupacionales.
- ✓ TEXTO: Ingreso promedio en dólares.
- ✓ FECHA: Porcentaje de mujeres por ocupación.
- ✓ **AUTOR:** Prestigio de la ocupación, resultado de una encuesta social realizada a mediados

#### **ANALISIS EXPLORATRIO:**

## 1. Cantidad de tweets y frecuencia de palabras



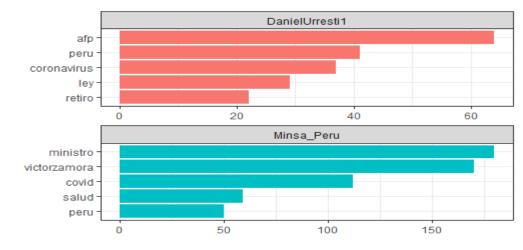
AUTOR	n_twits	palabras_utilizadas	palabras_diferentes	nedia_longitu sd	_longitud
DanielUrresti1	504	8.532	2.611	17,00	4,02
Minsa_Peru	414	6.804	1.644	16,40	1,73

En el dataset encontramos 504 tweets para DanielUrresti1 y 414 tweets para Minsa\_Peru, al analizar las palabras utilizadas se encontró que Urresti utilizo mayor cantidad de palabras con 31% palabras diferentes en sus tweets mientras que Minsa\_Peru tiene 24% de palabras diferentes. Respecto a Longitud media de los tweets por usuario, se observa que Minsa\_Peru alterna más entre tweets cortos y largos, siendo su media inferior a los tweets de DanielUrresti1.

### 2. Palabras más utilizadas por Autor

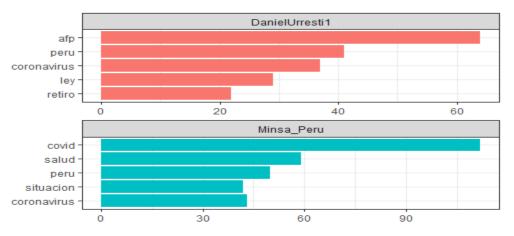
Las palabras más utilizadas para Urrestí son afp, peru, coronavirus, ley, retiro; se puede asumir por el contexto y el rango de fechas que se refiere al retiro de los fondos de las AFPs. En tanto para el MINSA son ministro, victorzamora, covid, salud, peru; por el contexto y las fechas mencionan con bastante énfasis al médico Víctor Zamora quién asumió el Ministerio de Salud los primeros meses de la pandemia.

### Universidad Ricardo Palma Escuela de Posgrado: Maestría en Ciencia de Datos Análisis Estadístico de Texto

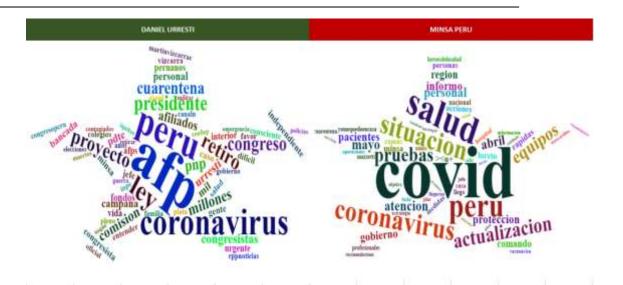




Al filtrar las palabras ministro y victorzamora, las palabras top 5 no se modifican para Urresti mientras que en Minsa sobresale situacion y coronavirus. Y se confirma que Urresti ha usado una mayor variedad léxica como ya se había evidenciado al realizar la variación estándar y la diferencia de palabras de la primera parte.

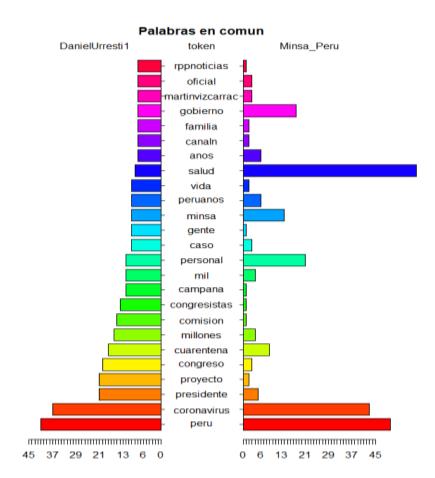


### Universidad Ricardo Palma Escuela de Posgrado: Maestría en Ciencia de Datos Análisis Estadístico de Texto



### 3. Palabras en común

Se encontró 302 palabras en común, destacando salud, peru, coronavirus, personal, gobierno, minsa. Se observa que las palabras que usa Urresti son utiliza las mismas palabras de modo más constante mientras el Minsa varia mucho en el lexico.





## Universidad Ricardo Palma Escuela de Posgrado: Maestría en Ciencia de Datos Análisis Estadístico de Texto

**MODELAMIENTO:**