

# I Introducción

**Fundamentos Matemáticos**  
**Función de Pérdida y Descenso de Gradiente**

Odin Eufracio

# Motivación

Algoritmos clásicos en **aprendizaje máquina** generalmente usan métodos de **optimización**, como descenso de gradiente, para la etapa de **entrenamiento o aprendizaje**.

Las redes neuronales, **neural networks (NN)**, son **modelos paramétricos** que también usan métodos de optimización en su etapa de aprendizaje.


En esta primera sección, implementaremos un modelo de **Regresión Lineal y Logística** para recordar conceptos claves como:

- Modelo paramétrico.
- Funciones de activación y pérdida.
- Optimización (descenso de gradiente)
- Aprendizaje o entrenamiento.

Más adelante veremos que las NN, **deep learning (DL)**, puede verse como un **conjunto apilado de modelos simples** como la Regresión Lineal o Logística.


# Regresión Lineal

# Regresión Lineal: Boston house prices data set



Cómo podemos modelar estos datos?

# Regresión Lineal: Boston house prices data set



Cuál es el modelo?

Cuáles son los parámetros del modelo?

Cómo estimamos los parámetros (óptimos) del modelo propuesto?

# Regresión Lineal: Boston house prices data set

Definimos una función de costo o función de pérdida (***Loss Function***)

# Regresión Lineal: Boston house prices data set

Definimos una función de costo o función de pérdida (***Loss Function***)

$$J(w, b) = \frac{1}{2} \sum_{i=1}^n [\hat{y}_i - y_i]^2 = \frac{1}{2} \sum_{i=1}^n [(wx + b) - y_i]^2$$

# Regresión Lineal: Boston house prices data set

Definimos una función de costo o función de pérdida (***Loss Function***)

$$J(w, b) = \frac{1}{2} \sum_{i=1}^n [\hat{y}_i - y_i]^2 = \frac{1}{2} \sum_{i=1}^n [(wx + b) - y_i]^2$$

Formulamos el problema de optimización



# Regresión Lineal: Boston house prices data set

Definimos una función de costo o función de pérdida (***Loss Function***)

$$J(w, b) = \frac{1}{2} \sum_{i=1}^n [\hat{y}_i - y_i]^2 = \frac{1}{2} \sum_{i=1}^n [(wx + b) - y_i]^2$$

Formulamos el problema de optimización

$$\min_{w, b} J(w, b)$$

# Regresión Lineal: Boston house prices data set

Definimos una función de costo o función de pérdida (***Loss Function***)

$$J(w, b) = \frac{1}{2} \sum_{i=1}^n [\hat{y}_i - y_i]^2 = \frac{1}{2} \sum_{i=1}^n [(wx + b) - y_i]^2$$

Formulamos el problema de optimización

$$\min_{w, b} J(w, b)$$

Ahora, cómo resolvemos este problema de optimización?

# Regresión Lineal: Boston house prices data set

Definimos una función de costo o función de pérdida (***Loss Function***)

$$J(w, b) = \frac{1}{2} \sum_{i=1}^n [\hat{y}_i - y_i]^2 = \frac{1}{2} \sum_{i=1}^n [(wx + b) - y_i]^2$$

Formulamos el problema de optimización

$$\min_{w, b} J(w, b)$$

Ahora, cómo resolvemos este problema de optimización?

Búsqueda en línea, ***gradient descent (GD)***.

$$x^{t+1} = x^t + \alpha p^t$$

Usando GD, nuestro modelo **aprenderá** los parámetros óptimos.

Vamos a **entrenar** nuestro modelo.

# Regresión Lineal: Boston house prices data set

Búsqueda en línea, *gradient descent (GD)*.

$$x^{t+1} = x^t + \alpha p^t$$

GD es un **método iterativo**, donde el número de iteraciones se le conoce como *epochs*.


El vector  $p$  se le conoce como la **dirección de descenso**, donde el negativo del gradiente de la función  $-\nabla J$  es la **dirección de máximo descenso**.

$$p^t = -\nabla J(x^t)$$

En cada iteración,  $x$  se mueve *un poco* en la dirección de  $p$ , donde  $\alpha$  es el tamaño de paso, *learning rate*, en que se moverá  $x$ .

# Actividad1


Terminar el notebook **1.1\_RegresionLineal.ipynb**



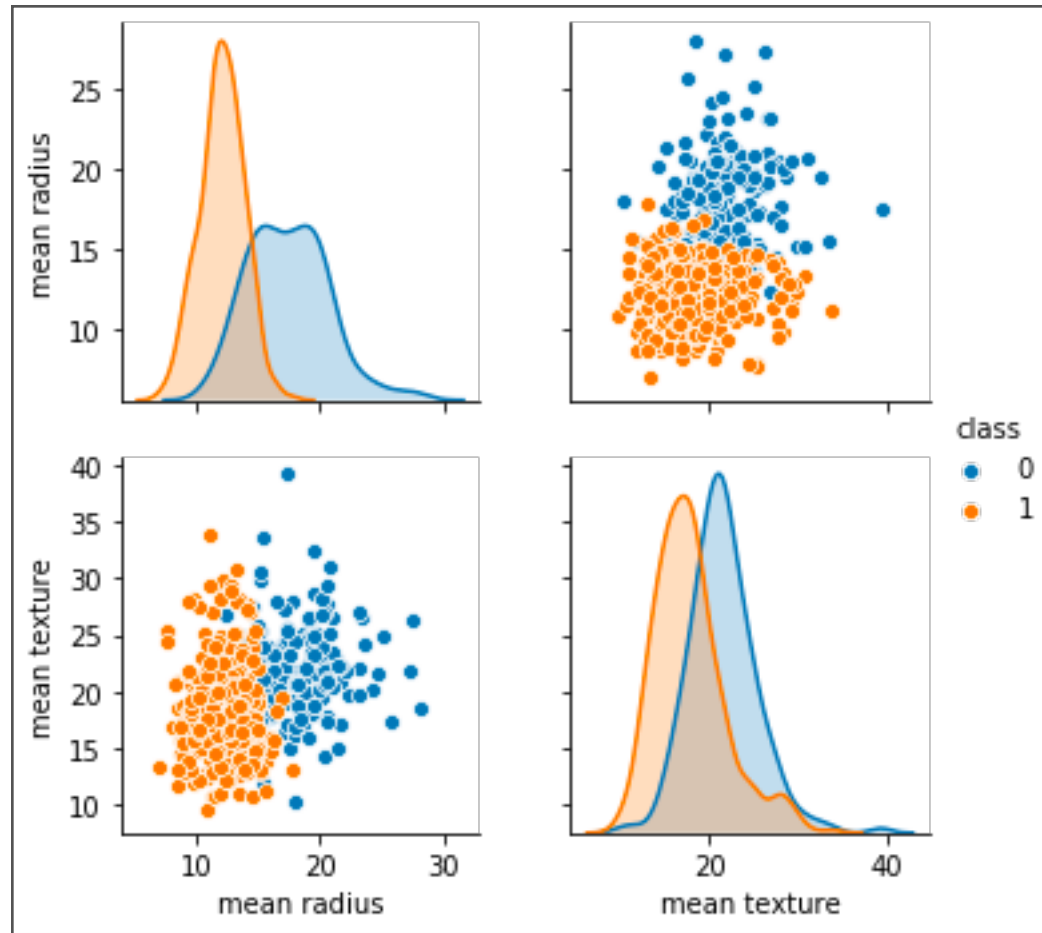
Retroalimentación.

# Regresión Logística

# Regresión Logística: Breast cancer wisconsin dataset



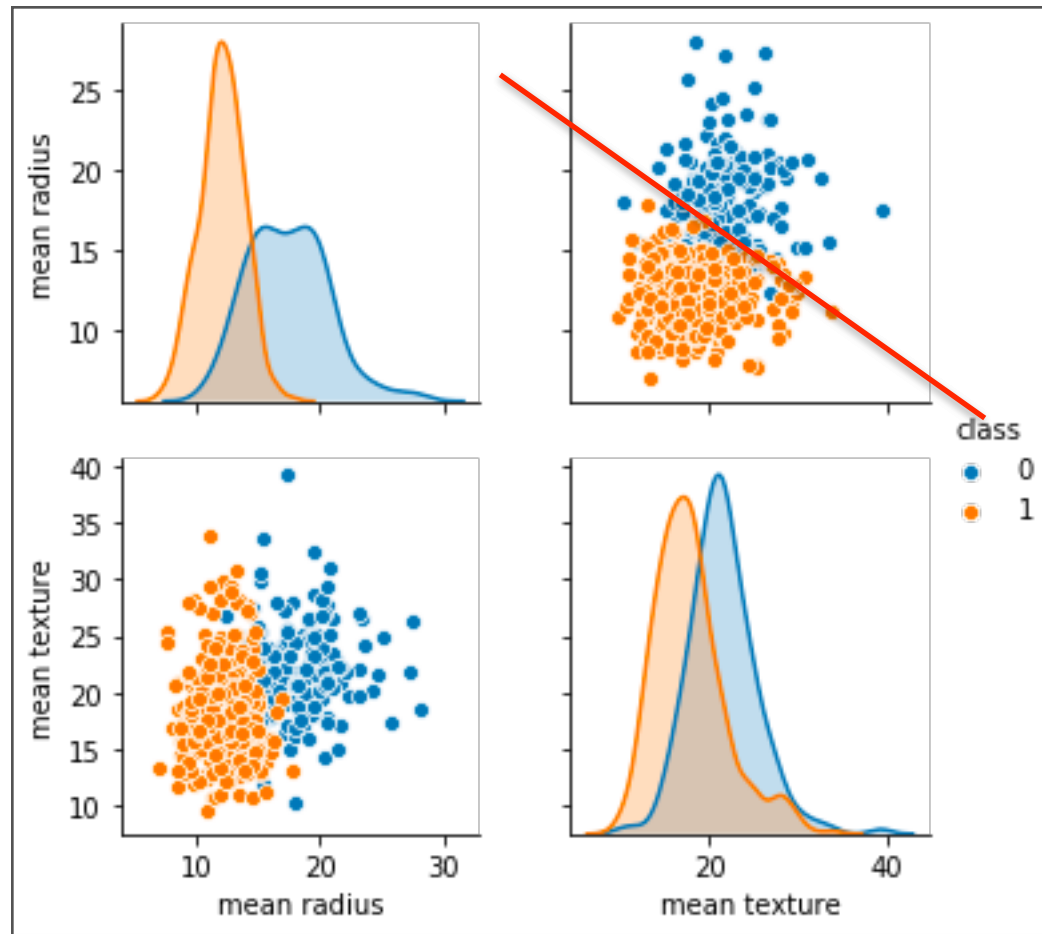
# Regresión Logística: Breast cancer wisconsin dataset





# Regresión Logística: Breast cancer wisconsin dataset

$$\hat{y}_i = \sigma(w^T x_i + b)$$





# Regresión Logística: Breast cancer wisconsin dataset

$$\hat{y}_i = wx_i + b$$

$$\hat{y}_i = \sigma(w^T x_i + b)$$


$$\sigma(w^T x + b) = \frac{1}{1 + e^{-(w^T x + b)}}$$




# Regresión Logística: Breast cancer wisconsin dataset

De igual forma, definimos una función de pérdida (**Loss Function**), con  $\sigma(x)$  como una función de activación (**activation function**)

$$J(w, b) = \frac{1}{2} \sum_{i=1}^n -y_i \log[\sigma(w^t x_i + b)] - (1 - y_i) \log[1 - \sigma(w^t x_i + b)]$$



$\log(x)$



$\frac{1}{1 + e^{-x}}$

## **Odin Eufracio**

Centro de Investigación en Matemáticas - CIMAT  
Jalisco SN, Mineral de Valenciana Gto. Gto.

Office: D307

Phone: (+52) 473 732 7155 ext. 4730

E-Mail: [odin.eufracio@cimat.mx](mailto:odin.eufracio@cimat.mx)